Quem sobreviveu ao Titanic? Uma análise com modelos lineares generalizados

Trabalho da disciplina de Modelos Lineares Generalizados (EST079)

Andrei Gustavo Sartao Lucas Teodoro de Paula Silva
Ewerton Albuquerque do Nascimento Cassio Alexandre dos Santos
Gabriel Vilela Lin

2026-11-11

Resumo

Este trabalho analisa os fatores associados à sobrevivência de passageiros do naufrágio do Titanic, em 1912. A variável resposta indica se a pessoa sobreviveu. As explicativas são classe, idade, sexo e se o passageiro viajava sozinho. Comparamos três funções de ligação para o modelo binomial (logit, probit e complemento log-log), escolhemos um modelo por validação cruzada repetida e avaliamos seu desempenho em um conjunto de teste separado. Os resultados indicam que sexo, classe e idade estão associados à sobrevivência.

Índice

1 Introdução **1**

2 Os dados **1**

3 Análise exploratória **2**

4 Modelos no banco completo **4**
4.1 Efeitos no modelo logit 4
4.2 Comparação das ligações 5
4.3 Importância de cada termo 5

5 Divisão em treino e teste **6**

6 Validação cruzada repetida **6**

7 Modelo final **7**
7.1 Resíduos 7

8 Probabilidades previstas **8**

9 Desempenho no conjunto de teste **9**

10 Discussão **10**

11 Conclusões **11**

12 Limitações **11**

1 Introdução

O navio Titanic naufragou em 14 de abril de 1912, na sua viagem inaugural. Este trabalho usa o banco `titanic.csv`, com informações de passageiros do navio. Nosso objetivo é entender quais características estão associadas à sobrevivência.

Temos três objetivos:

1. Descrever o perfil dos passageiros e a sobrevivência em cada grupo.
2. Ajustar modelos binomiais com três funções de ligação e comparar seu ajuste.
3. Escolher um modelo por validação cruzada e avaliar seu desempenho em dados novos.

Nota: Por que um modelo linear generalizado?

A variável resposta tem apenas dois resultados: sobreviveu ou não. Por isso usamos a distribuição binomial, que pertence à família exponencial. A função de ligação conecta a probabilidade de sobreviver às variáveis explicativas. Comparamos três ligações: logit, probit e complemento log-log (cloglog).

2 Os dados

A Tabela 1 descreve as variáveis. O banco tem 714 passageiros e 0 valores faltantes. Há 281 linhas repetidas, que mantivemos e discutimos na seção de limitações.

Tabela 1: Variáveis do banco de dados.

Variável	Tipo	Categorias
vivo	Categórica (resposta)	sim, não
classe	Categórica	I, II, III
idade	Numérica	anos
sexo	Categórica	feminino, masculino
sozinho	Categórica	sim, não

3 Análise exploratória

A Tabela 2 mostra a proporção geral de sobreviventes.

Tabela 2: Sobreviventes e não sobreviventes.

Resultado	Passageiros	Proporção
Não sobreviveu	424	59,4%
Sobreviveu	290	40,6%

No geral, 40,6% dos passageiros sobreviveram. Porém, essa média esconde diferenças grandes entre os grupos, como mostram a Figura 1 e a Tabela 3.

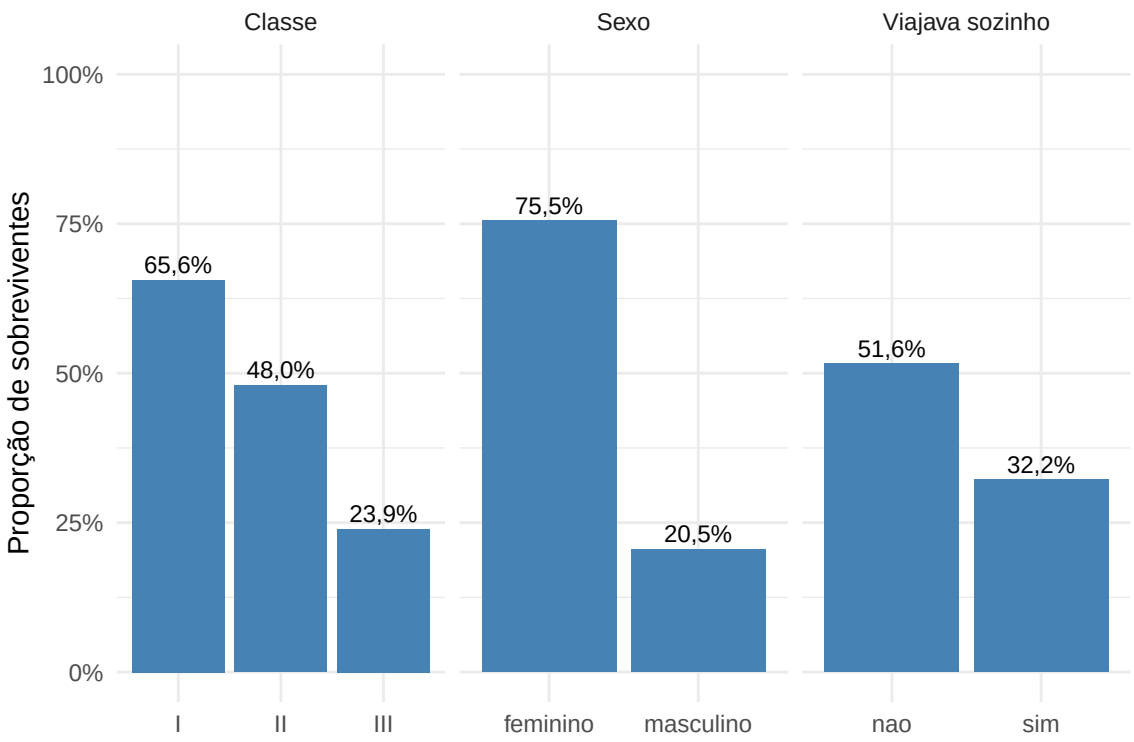


Figura 1: Proporção de sobreviventes em cada categoria. Os rótulos mostram a porcentagem.

Tabela 3: Proporção de sobreviventes por sexo e classe, com o número de passageiros entre parênteses.

Sexo	Classe I	Classe II	Classe III
Feminino	96,5% (85)	91,9% (74)	46,1% (102)
Masculino	39,6% (101)	15,2% (99)	15,0% (253)

A Figura 2 mostra a mesma combinação de sexo e classe em forma de mapa de calor. A diferença entre mulheres e homens é grande em todas as classes.

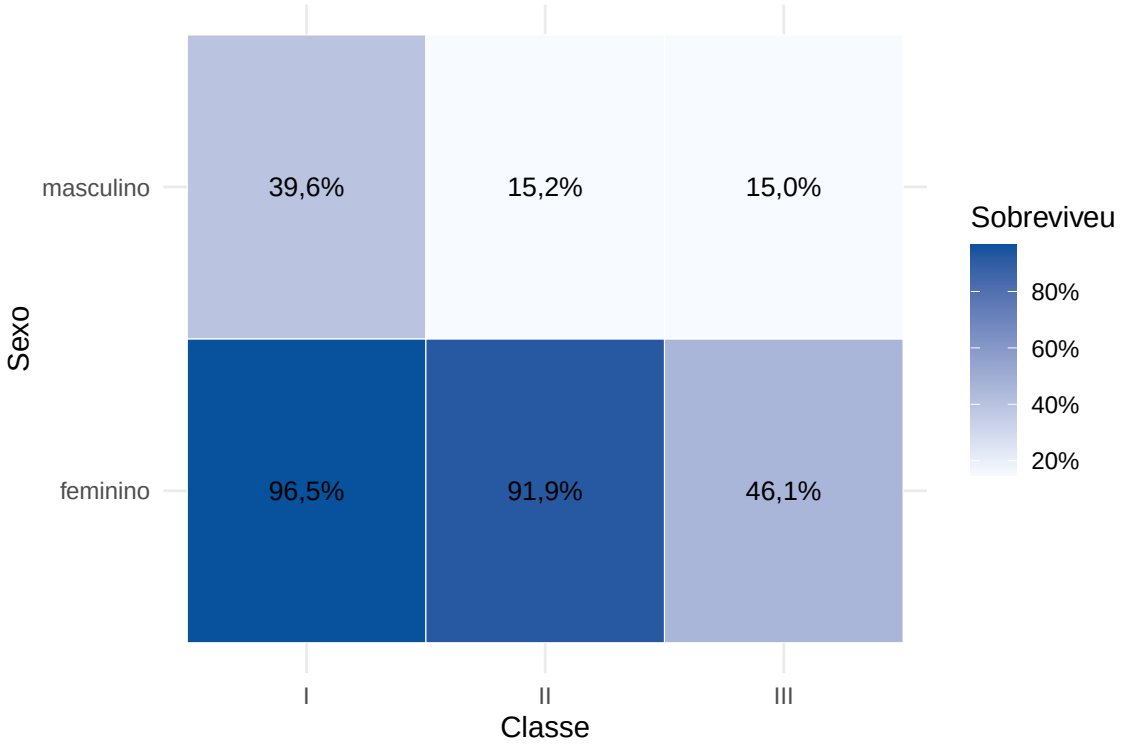


Figura 2: Proporção de sobreviventes por sexo e classe.

A Figura 3 mostra a distribuição da idade nos dois grupos. As idades têm formato parecido, mas a média dos sobreviventes é ligeiramente menor. A mediana é igual nos dois grupos.

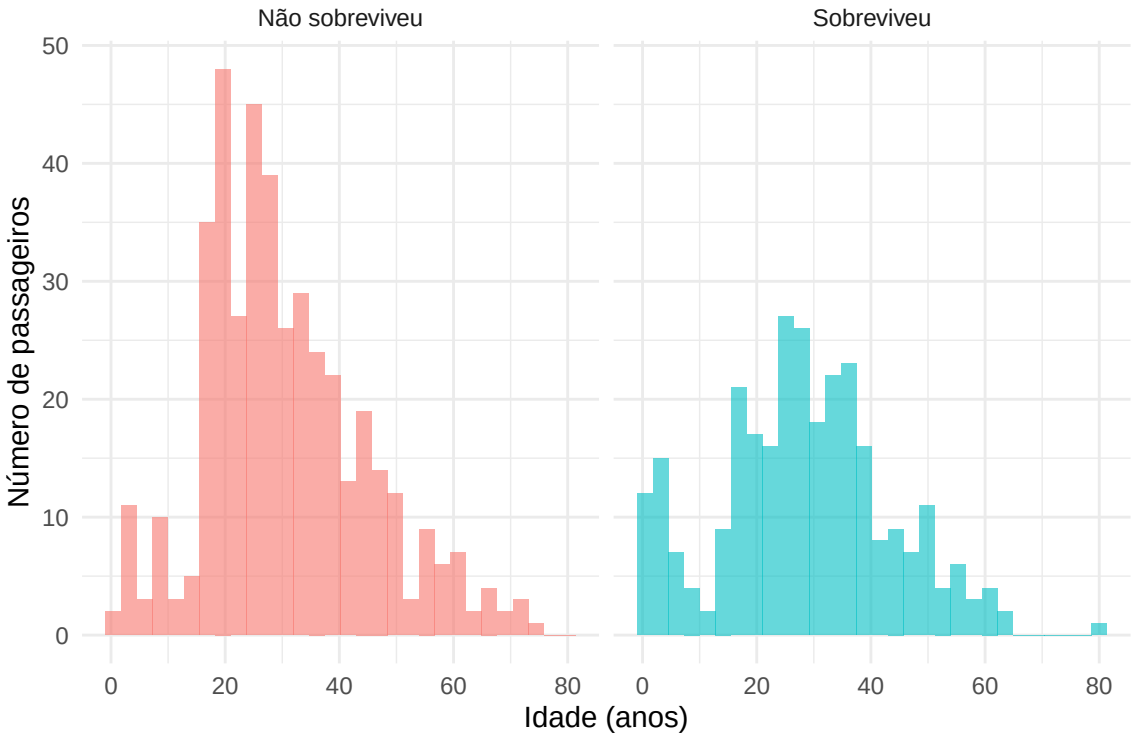


Figura 3: Distribuição da idade, separada pela sobrevivência.

Sexo e classe aparecem como os primeiros sinais de diferença. Essa leitura é só descritiva. Para

saber se a diferença se mantém quando as outras variáveis entram na conta, precisamos do modelo.

4 Modelos no banco completo

Para cada passageiro i, seja π_i a probabilidade de sobreviver. O modelo liga π_i ao preditor linear η_i, com as variáveis explicativas:

$$g(\pi_i) = \eta_i = \beta_0 + \beta_1\,\text{classe}_{II,i} + \beta_2\,\text{classe}_{III,i} + \beta_3\,\text{idade}_i + \beta_4\,\text{sexo}_{masc,i} + \beta_5\,\text{sozinho}_{sim,i}.$$

As três funções de ligação são:

- **Logit:** $g(\pi) = \log\{\pi/(1-\pi)\}$.
- **Probit:** $g(\pi) = \Phi^{-1}(\pi)$, em que Φ é a função de distribuição normal padrão.
- **Complemento log-log (cloglog):** $g(\pi) = \log\{-\log(1-\pi)\}$.

Na análise completa, ajustamos os três modelos com todas as variáveis.

4.1 Efeitos no modelo logit

A Tabela 4 apresenta os efeitos no modelo logit como razões de chances (odds ratio, OR). Uma razão de chances menor que 1 indica menor chance de sobreviver, em relação à categoria de referência, mantendo as outras variáveis fixas.

Tabela 4: Razões de chances (OR) do modelo logit com todas as variáveis.

Termo	OR	IC 95%	Valor p
Intercepto	44,089	[20,528; 99,493]	$< 0{,}001$
Classe II (ref.: classe I)	0,263	[0,150; 0,453]	$< 0{,}001$
Classe III (ref.: classe I)	0,073	[0,041; 0,127]	$< 0{,}001$
Idade (por ano)	0,963	[0,947; 0,977]	$< 0{,}001$
Sexo masculino (ref.: feminino)	0,078	[0,050; 0,117]	$< 0{,}001$
Viajava sozinho (ref.: não)	1,145	[0,763; 1,733]	0,516

A Figura 4 mostra os mesmos intervalos em forma gráfica. A escala é logarítmica, então a linha pontilhada em 1 marca o ponto “sem efeito”.

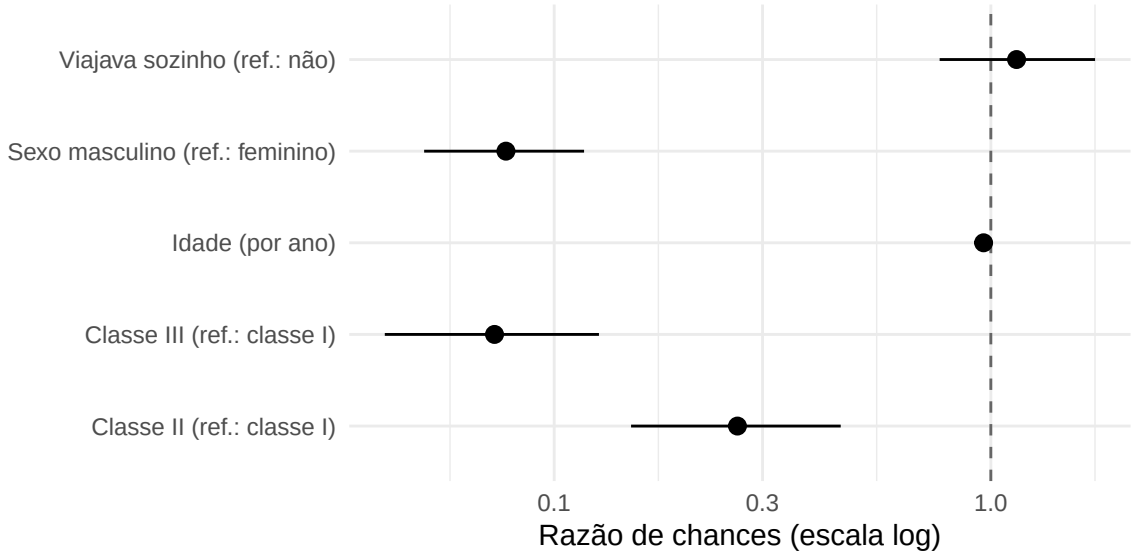


Figura 4: Razões de chances com intervalo de confiança de 95% (modelo logit). Escala logarítmica.

4.2 Comparação das ligações

A Tabela 5 compara as três ligações pelo AIC (critério de Akaike, em que menor é melhor) e pela deviance residual.

Tabela 5: Comparação das funções de ligação na análise completa.

Ligação	AIC	Deviance residual
Logit	658,9	646,9
Probit	661,3	649,3
Cloglog	653,3	641,3

4.3 Importância de cada termo

A Tabela 6 testa a retirada de cada termo do modelo logit, pelo teste da razão de verossimilhanças. Um termo com p pequeno é importante para o modelo.

Tabela 6: Teste da razão de verossimilhanças para cada termo do modelo logit.

Termo	Graus de liberdade	Deviance	AIC	Valor p
Nenhum termo (modelo completo)	-	646,9	658,9	-
classe	2	748,1	756,1	$< 0{,}001$
idade	1	672,1	682,1	$< 0{,}001$
sexo	1	821,1	831,1	$< 0{,}001$
sozinho	1	647,3	657,3	0,515

Como o termo `sozinho` tem o maior valor p, testamos formalmente se ele pode sair do modelo. A Tabela 7 compara o modelo sem `sozinho` com o modelo completo.

Tabela 7: Comparação do modelo reduzido (sem sozinho) com o modelo completo.

Modelo	Deviance residual	Graus de liberdade	Valor p
Sem sozinho	647,28	709	-
Completo	646,86	708	0,515

Atenção: Cuidado na interpretação

O termo `sozinho` não tem efeito detectável quando sexo, idade e classe estão no modelo. Isso não significa que viajar sozinho não tenha relação nenhuma com a sobrevivência. Na tabela descritiva, quem viajava sozinho sobreviveu menos. Esse efeito bruto pode vir, em parte, da composição dos grupos por sexo, idade e classe.

5 Divisão em treino e teste

Separamos 75% dos passageiros para ajustar e escolher o modelo (treino) e 25% para avaliar o modelo final (teste). A divisão manteve a proporção de sobreviventes nos dois conjuntos.

Tabela 8: Número de passageiros em cada conjunto.

Conjunto	Não sobreviveu	Sobreviveu
Treino	318	217
Teste	106	73

6 Validação cruzada repetida

No conjunto de treino, repetimos a validação cruzada em 10 partes (*folds*), 5 vezes. Assim, cada modelo é avaliado 50 vezes em partes diferentes dos dados.

A receita padroniza a idade e transforma as categorias em variáveis dummy. Em seguida, comparamos os três modelos pelas métricas da Tabela 9.

Tabela 9: Médias das métricas na validação cruzada (50 repetições por modelo). Quanto maior a AUC e a acurácia, melhor. Quanto menor o escore de Brier, melhor.

Modelo	AUC	Escore de Brier	Acurácia
Logit	0,843	0,150	0,786
Probit	0,842	0,150	0,789
Cloglog	0,842	0,149	0,772

Os três modelos ficaram muito próximos. O logit teve a maior AUC média e foi escolhido como modelo final, pelo critério usual de maior AUC na validação cruzada.

Importante: Diferença pequena não prova superioridade

As AUCs dos três modelos diferem em centésimos. Uma diferença tão pequena não permite dizer que um modelo é melhor que o outro. A escolha do logit segue o critério combinado, mas não deve ser interpretada como evidência forte.

7 Modelo final

A Tabela 10 mostra os coeficientes do modelo final. Como a idade foi padronizada na receita, o efeito da idade aparece na escala padronizada. Por isso, o sinal é o que importa aqui. As razões de chances estão na Tabela 4.

Tabela 10: Coeficientes do modelo final, ajustado no conjunto de treino (escala padronizada).

Termo	Coeficiente	Erro padrão	Valor p
(Intercept)	2,706	0,307	$< 0,001$
idade	-0,443	0,132	$< 0,001$
classe_II	-1,517	0,329	$< 0,001$
classe_III	-2,648	0,337	$< 0,001$
sexo_masculino	-2,402	0,243	$< 0,001$
sozinho_sim	0,014	0,242	0,952

7.1 Resíduos

A Figura 5 mostra os resíduos deviance contra as probabilidades ajustadas.

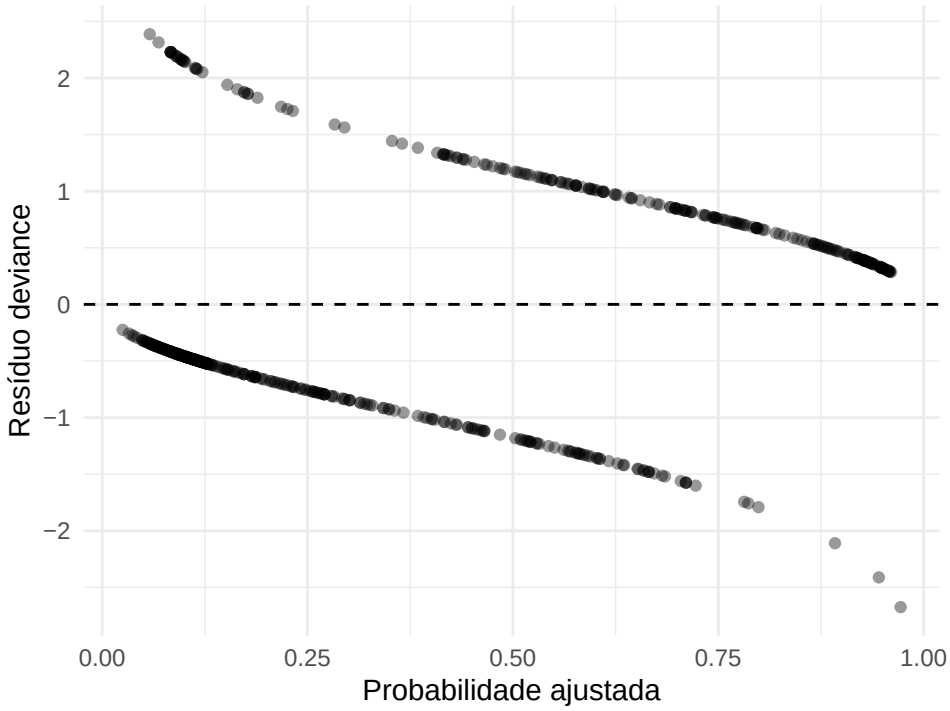


Figura 5: Resíduos deviance do modelo final contra as probabilidades ajustadas.

Como a resposta é binária, os resíduos formam duas faixas, uma para cada resultado. Essa forma é esperada neste tipo de modelo. Por isso, o gráfico ajuda pouco a detectar problemas.

8 Probabilidades previstas

Uma forma útil de entender o modelo é ver a probabilidade prevista de sobreviver para diferentes perfis. A Figura 6 mostra a curva para cada classe, separada por sexo. Para simplificar, fixamos `sozinho` em "não" (viajando acompanhado).

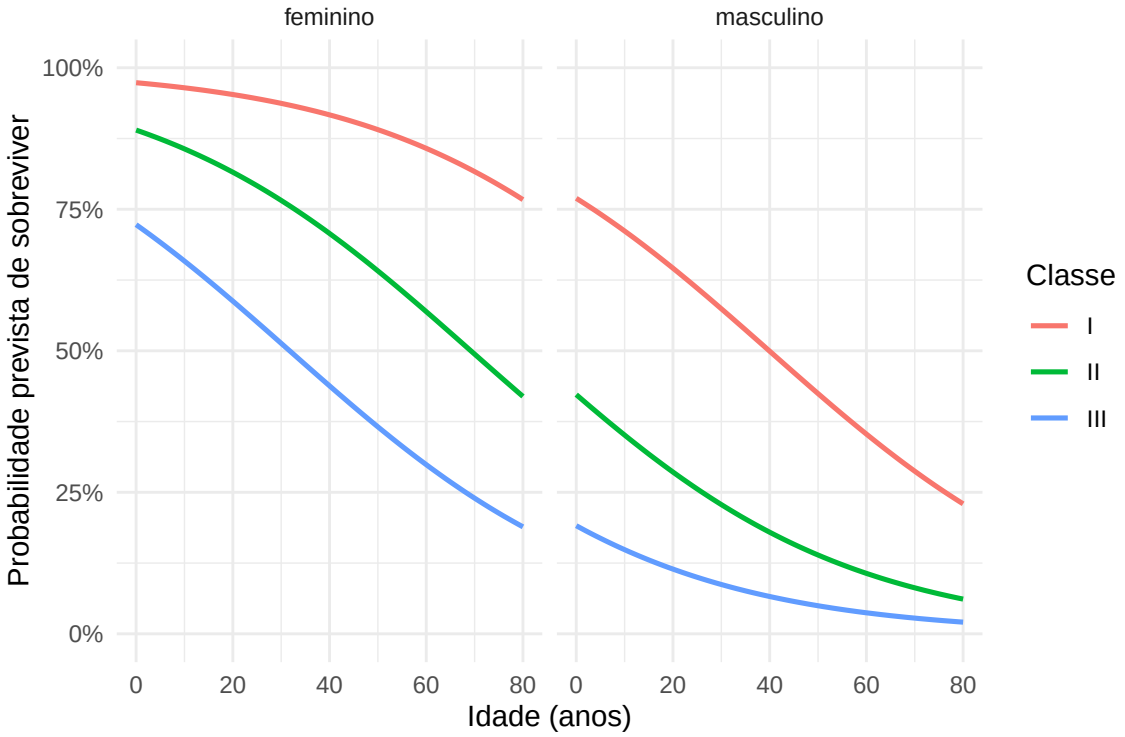


Figura 6: Probabilidade prevista de sobreviver segundo idade, classe e sexo. Todos os perfis foram calculados como viajando acompanhados.

A Tabela 11 mostra a probabilidade para alguns perfis escolhidos.

Tabela 11: Probabilidade prevista de sobreviver para perfis escolhidos (modelo final).

Perfil	Probabilidade prevista
Mulher de 30 anos, classe I, acompanhada	93,7%
Homem de 30 anos, classe I, acompanhado	57,4%
Mulher de 30 anos, classe III, acompanhada	51,3%
Homem de 30 anos, classe III, acompanhado	8,7%
Criança de 5 anos, classe III, acompanhada	69,2%

9 Desempenho no conjunto de teste

Agora avaliamos o modelo final nos 179 passageiros que não foram usados no ajuste.

Usamos “sim” como evento de interesse (`event_level = "second"`). O escore de Brier é calculado diretamente, pois a versão do pacote com esse argumento deu um valor incorreto nesta análise.

Tabela 12: Métricas no conjunto de teste.

Métrica	Valor
AUC (área sob a curva ROC)	0,866
Acurácia	0,804
Sensibilidade (sobreviventes identificados)	0,795
Especificidade (não sobreviventes identificados)	0,811
Valor preditivo positivo	0,744

Tabela 12: Métricas no conjunto de teste.

Métrica	Valor
Valor preditivo negativo	0,851
Escore de Brier	0,140

A Tabela 13 mostra a matriz de confusão, com o ponto de corte de 0,5.

Tabela 13: Matriz de confusão no conjunto de teste (ponto de corte de 0,5).

Previsto	Observado: não sobreviveu	Observado: sobreviveu
Não sobreviveu	86	15
Sobreviveu	20	58

A Figura 7 mostra a curva ROC no conjunto de teste.

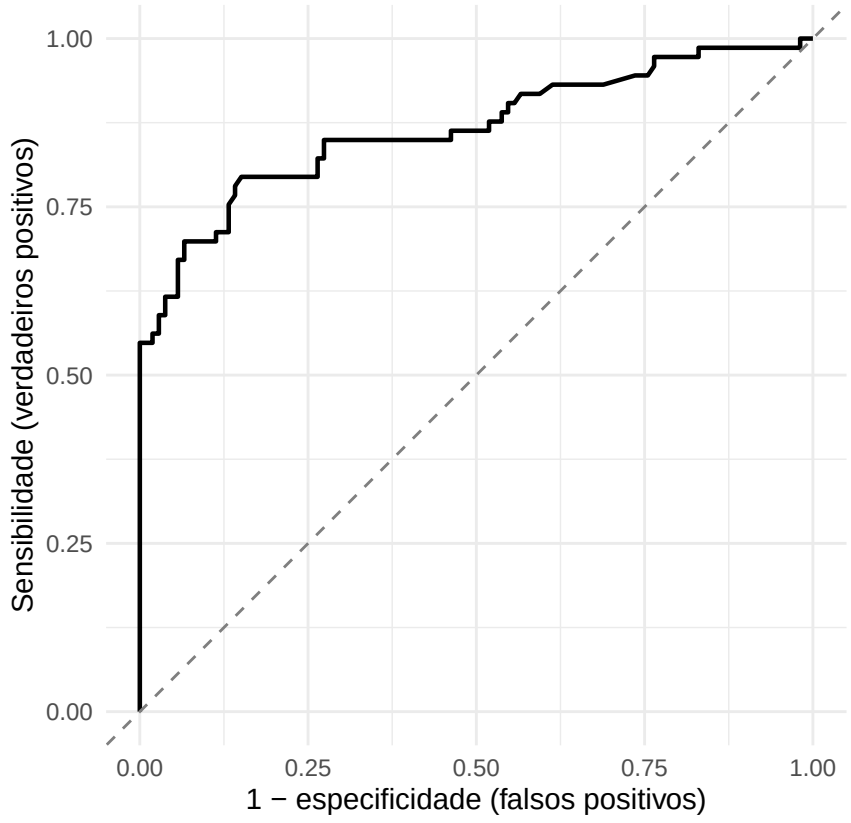


Figura 7: Curva ROC no conjunto de teste.

Para conferir, calculamos a AUC com o pacote `pROC`.

A AUC calculada pelo `pROC` foi 0,866, igual à do yardstick.

10 Discussão

Os resultados confirmam a diferença observada na análise descritiva. Mesmo ajustando para as outras variáveis, o sexo tem o efeito mais forte. A razão de chances de um homem, em relação a

uma mulher, foi de 0,078.

A classe também tem efeito claro. Passageiros da classe III tiveram chance bem menor que os da classe I. A idade tem efeito pequeno por ano, mas esse efeito se acumula: para dez anos a mais, a razão de chances é de cerca de 0,682.

11 Conclusões

- O sexo, a classe e a idade estão associados à sobrevivência, mesmo com as outras variáveis fixas.
- O efeito de viajar sozinho não é detectável no modelo completo.
- As três funções de ligação têm desempenho muito parecido. O logit foi escolhido pelo critério de maior AUC na validação cruzada.
- No conjunto de teste, o modelo final tem AUC de 0,866 e acurácia de 0,804.

12 Limitações

- O banco tem 281 linhas repetidas. Como não há identificador de passageiro, não sabemos se são pessoas diferentes com as mesmas características. Mantivemos as linhas, mas repetições podem tornar as métricas da validação cruzada um pouco otimistas.
- Os resultados mostram associação, não causa.
- Os dados se referem a um único naufrágio, de 1912, e não a outros cenários.