Análise dos sobreviventes do naufrágio do Titanic

Modelos Lineares Generalizados — Regressão binária

2026-11-11

Índice

1 Introdução **1**

2 Preparação dos dados **2**

3 Análise exploratória **2**

4 Modelos GLM no banco completo **4**

5 Divisão em treino e teste **6**

6 Validação cruzada repetida **6**

7 Receita de pré-processamento **6**

8 Comparação dos modelos por validação cruzada **6**

9 Escolha e ajuste do modelo final **7**

10 Análise de resíduos do modelo final **8**

11 Avaliação no conjunto de teste **9**

12 Conclusões **11**

1 Introdução

Este trabalho analisa o arquivo `titanic.csv`, com informações sobre o naufrágio do navio Titanic, ocorrido em 14 de abril de 1912, em sua viagem inaugural. O banco tem 714 passageiros e as seguintes variáveis:

- **vivo**: se a pessoa sobreviveu (`sim`) ou não (`nao`) ao naufrágio. É a variável resposta.
- **classe**: classe do passageiro no navio (`I`, `II` ou `III`).
- **idade**: idade do passageiro, em anos.
- **sexo**: `feminino` ou `masculino`.
- **sozinho**: se o passageiro viajava sozinho (`sim`) ou acompanhado (`nao`).

Como a variável resposta tem duas categorias, usamos modelos lineares generalizados (MLG) com distribuição binomial. Comparamos três funções de ligação: logit, probit e complemento log-log (cloglog).

```
library(tidyverse)
library(tidymodels)
```

```r
library(pROC)
tidymodels_prefer()
theme_set(theme_minimal(base_size = 11))
```

2 Preparação dos dados

```r
titanic <- read_csv("titanic.csv", show_col_types = FALSE)

# A categoria "sim" fica por último, para ser tratada como sucesso (evento).
dados <- titanic |>
  mutate(
    vivo = factor(vivo, levels = c("nao", "sim")),
    classe = factor(classe, levels = c("I", "II", "III")),
    sexo = factor(sexo, levels = c("feminino", "masculino")),
    sozinho = factor(sozinho, levels = c("nao", "sim"))
  )

glimpse(dados)
```

```
Rows: 714
Columns: 5
$ vivo    <fct> nao, sim, sim, sim, nao, nao, nao, sim, sim, sim, sim, nao, na~
$ classe  <fct> III, I, III, I, III, I, III, III, II, III, I, III, III, III, I~
$ idade   <dbl> 22, 38, 26, 35, 35, 54, 2, 27, 14, 4, 58, 20, 39, 14, 55, 2, 3~
$ sexo    <fct> masculino, feminino, feminino, feminino, masculino, masculino,~
$ sozinho <fct> nao, nao, sim, nao, sim, sim, nao, nao, nao, nao, sim, sim, na~
```

```r
# Valores faltantes e linhas repetidas
sum(is.na(dados))
```

```
[1] 0
```

```r
sum(duplicated(dados))
```

```
[1] 281
```

3 Análise exploratória

```r
dados |>
  count(vivo) |>
  mutate(proporcao = n / sum(n))
```

```
# A tibble: 2 x 3
  vivo      n proporcao
  <fct> <int>     <dbl>
1 nao     424     0.594
2 sim     290     0.406
```

```r
resumo_cat <- dados |>
  pivot_longer(
    c(classe, sexo, sozinho),
    names_to = "variavel",
    values_to = "categoria"
```

```
  ) |>
  group_by(variavel, categoria) |>
  summarise(
    n = n(),
    prop_sobreviveu = mean(vivo == "sim"),
    .groups = "drop"
  )

resumo_cat
```

```
# A tibble: 7 x 4
  variavel categoria     n prop_sobreviveu
  <chr>    <fct>     <int>           <dbl>
1 classe   I           186           0.656
2 classe   II          173           0.480
3 classe   III         355           0.239
4 sexo     feminino    261           0.755
5 sexo     masculino   453           0.205
6 sozinho  nao         310           0.516
7 sozinho  sim         404           0.322
```

```
resumo_cat |>
  ggplot(aes(x = categoria, y = prop_sobreviveu)) +
  geom_col(fill = "steelblue") +
  geom_text(aes(label = scales::percent(prop_sobreviveu, accuracy = 1)),
            vjust = -0.4, size = 3) +
  facet_wrap(~variavel, scales = "free_x") +
  scale_y_continuous(labels = scales::percent, limits = c(0, 1)) +
  labs(x = NULL, y = "Proporção de sobreviventes")
```

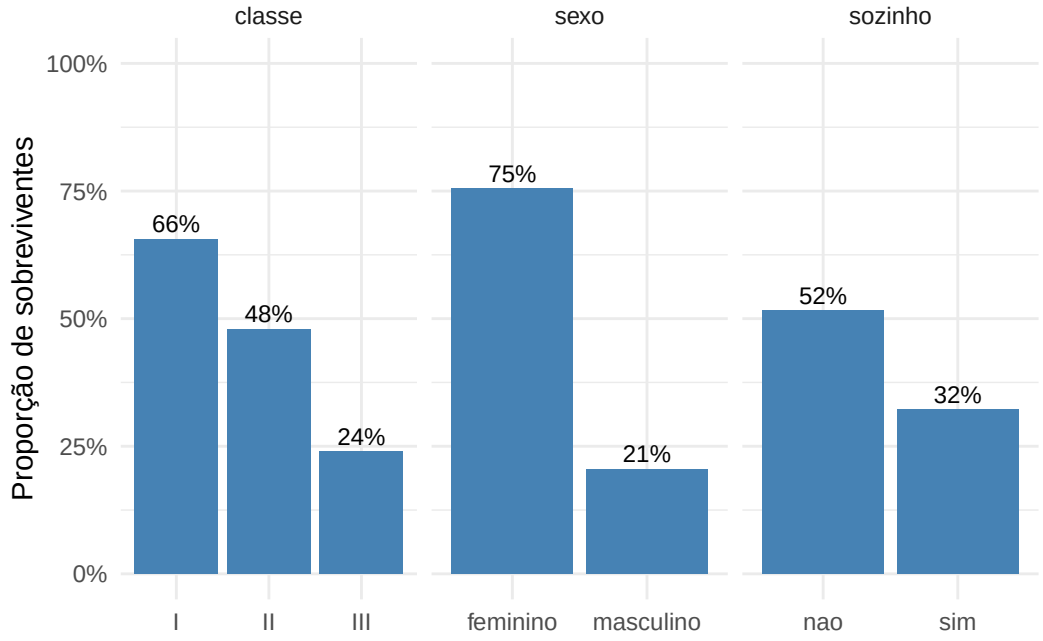


Figura 1: Proporção de sobreviventes em cada categoria.

```r
ggplot(dados, aes(x = vivo, y = idade, fill = vivo)) +
  geom_boxplot(show.legend = FALSE) +
  labs(x = "Sobreviveu", y = "Idade (anos)")
```

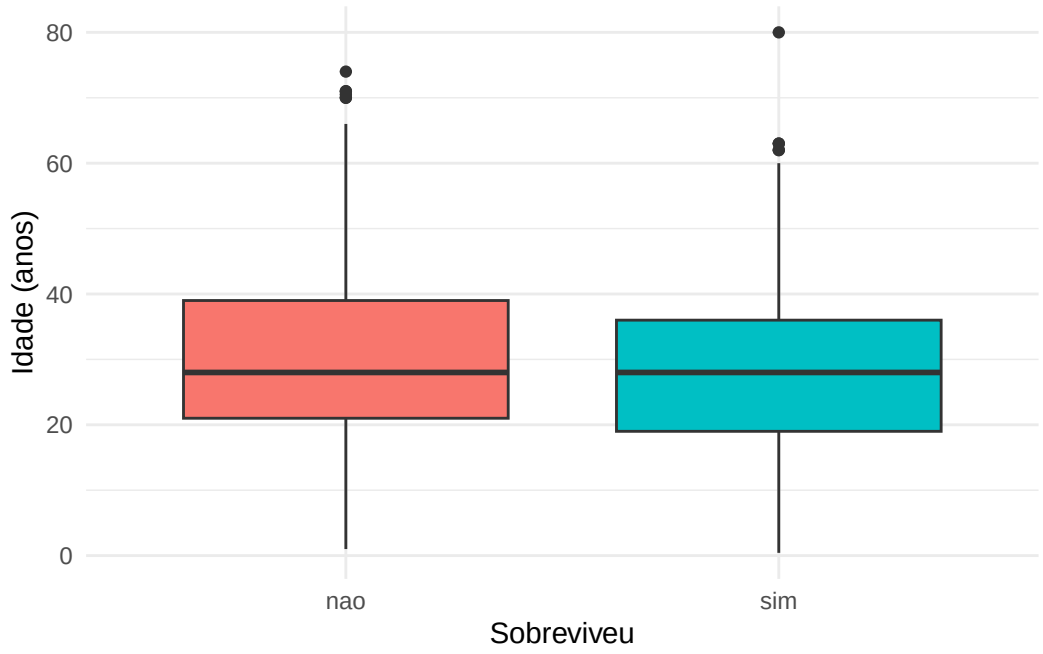


Figura 2: Distribuição da idade segundo a sobrevivência.

```r
dados |>
  group_by(vivo) |>
  summarise(
    media = mean(idade),
    mediana = median(idade),
    .groups = "drop"
  )
```

```
# A tibble: 2 x 3
  vivo  media mediana
  <fct> <dbl>   <dbl>
1 nao    30.6      28
2 sim    28.3      28
```

4 Modelos GLM no banco completo

Primeiro ajustamos os três modelos com todas as variáveis explicativas. Esta etapa serve para interpretar os coeficientes.

```r
formula_completa <- vivo ~ classe + idade + sexo + sozinho

fit_logit <- glm(
  formula_completa, data = dados,
  family = binomial(link = "logit")
)
fit_probit <- glm(
  formula_completa, data = dados,
```

```
  family = binomial(link = "probit")
)
fit_cloglog <- glm(
  formula_completa, data = dados,
  family = binomial(link = "cloglog")
)
```

Coeficientes do modelo logit. A coluna **estimate** está exponenciada, então é a razão de chances (odds ratio).

```
tidy(fit_logit, conf.int = TRUE, exponentiate = TRUE)
```

```
# A tibble: 6 x 7
  term          estimate std.error statistic  p.value conf.low conf.high
  <chr>            <dbl>     <dbl>     <dbl>    <dbl>    <dbl>     <dbl>
1 (Intercept)    44.1      0.402       9.42  4.71e-21  20.5       99.5
2 classeII        0.263    0.282      -4.74  2.09e- 6   0.150      0.453
3 classeIII       0.0730   0.288      -9.10  9.17e-20   0.0409     0.127
4 idade           0.963    0.00791    -4.83  1.34e- 6   0.947      0.977
5 sexomasculino   0.0775   0.215     -11.9   1.15e-32   0.0504     0.117
6 sozinhosim      1.15     0.209       0.649 5.16e- 1   0.763      1.73
```

Comparação das três ligações. Quanto menor o AIC, melhor o ajuste, considerando o número de parâmetros.

```
tibble(
  modelo = c("logit", "probit", "cloglog"),
  AIC = c(AIC(fit_logit), AIC(fit_probit), AIC(fit_cloglog)),
  deviance_residual = c(
    deviance(fit_logit), deviance(fit_probit), deviance(fit_cloglog)
  )
)
```

```
# A tibble: 3 x 3
  modelo    AIC deviance_residual
  <chr>   <dbl>             <dbl>
1 logit    659.              647.
2 probit   661.              649.
3 cloglog  653.              641.
```

Teste de razão de verossimilhanças para cada termo do modelo logit.

```
drop1(fit_logit, test = "Chisq")
```

```
Single term deletions

Model:
vivo ~ classe + idade + sexo + sozinho
        Df Deviance    AIC     LRT  Pr(>Chi)
<none>       646.86 658.86
classe   2   748.12 756.12 101.263 < 2.2e-16 ***
idade    1   672.10 682.10  25.246 5.047e-07 ***
sexo     1   821.11 831.11 174.253 < 2.2e-16 ***
sozinho  1   647.28 657.28   0.424    0.5147
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

5 Divisão em treino e teste

```
set.seed(123)
split <- initial_split(dados, prop = 0.75, strata = vivo)
treino <- training(split)
teste <- testing(split)

count(treino, vivo)
```

```
# A tibble: 2 x 2
  vivo      n
  <fct> <int>
1 nao     318
2 sim     217
```

```
count(teste, vivo)
```

```
# A tibble: 2 x 2
  vivo      n
  <fct> <int>
1 nao     106
2 sim      73
```

6 Validação cruzada repetida

```
set.seed(123)
vfolds <- vfold_cv(treino, v = 10, repeats = 5, strata = vivo)
```

7 Receita de pré-processamento

```
receita <- recipe(
  vivo ~ classe + idade + sexo + sozinho,
  data = treino
) |>
  step_normalize(all_numeric_predictors()) |>
  step_dummy(all_nominal_predictors())

# Fórmula gerada pela receita, com as variáveis dummy
receita |>
  prep() |>
  formula()
```

```
vivo ~ idade + classe_II + classe_III + sexo_masculino + sozinho_sim
<environment: 0x14b46a278>
```

8 Comparação dos modelos por validação cruzada

```
logit <- logistic_reg() |>
  set_engine("glm")

probit <- logistic_reg() |>
  set_engine("glm", family = stats::binomial(link = "probit"))
```

```r
cloglog <- logistic_reg() |>
  set_engine("glm", family = stats::binomial(link = "cloglog"))

modelos <- workflow_set(
  preproc = list(receita = receita),
  models = list(logit = logit, probit = probit, cloglog = cloglog)
)

modelos
```

```
# A workflow set/tibble: 3 x 4
  wflow_id        info             option    result
  <chr>           <list>           <list>    <list>
1 receita_logit   <tibble [1 x 4]> <opts[0]> <list [0]>
2 receita_probit  <tibble [1 x 4]> <opts[0]> <list [0]>
3 receita_cloglog <tibble [1 x 4]> <opts[0]> <list [0]>
```

```r
# Métricas probabilísticas
metricas_prob <- metric_set(roc_auc, brier_class, accuracy)

# Guarda as predições de cada dobra
ctrl <- control_resamples(save_pred = TRUE)

set.seed(123)
resultados <- workflow_map(
  modelos,
  fn = "fit_resamples",
  resamples = vfolds,
  metrics = metricas_prob,
  control = ctrl,
  verbose = FALSE
)
```

```r
metricas_cv <- collect_metrics(resultados)

metricas_cv |>
  select(wflow_id, .metric, mean, std_err) |>
  pivot_wider(names_from = .metric, values_from = c(mean, std_err)) |>
  arrange(desc(mean_roc_auc))
```

```
# A tibble: 3 x 7
  wflow_id        mean_accuracy mean_brier_class mean_roc_auc std_err_accuracy
  <chr>                   <dbl>            <dbl>        <dbl>            <dbl>
1 receita_logit           0.786            0.150        0.843          0.00834
2 receita_probit          0.789            0.150        0.842          0.00795
3 receita_cloglog         0.772            0.149        0.842          0.00929
# i 2 more variables: std_err_brier_class <dbl>, std_err_roc_auc <dbl>
```

9 Escolha e ajuste do modelo final

O melhor modelo é o que tem maior AUC (área sob a curva ROC) média na validação cruzada.

```r
best_model <- metricas_cv |>
  filter(.metric == "roc_auc") |>
```

```
  slice_max(order_by = mean, n = 1, with_ties = FALSE)

best_model
```

```
# A tibble: 1 x 9
  wflow_id      .config     preproc model .metric .estimator  mean     n std_err
  <chr>         <chr>       <chr>   <chr> <chr>   <chr>      <dbl> <int>   <dbl>
1 receita_logit pre0_mod0_~ recipe  logi~ roc_auc binary     0.843    50 0.00888
```

```
best_id <- best_model |>
  pull(wflow_id)

best <- extract_workflow(resultados, id = best_id)

final <- best |>
  fit(data = treino)

tidy(final)
```

```
# A tibble: 6 x 5
  term           estimate std.error statistic  p.value
  <chr>             <dbl>     <dbl>     <dbl>    <dbl>
1 (Intercept)      2.71       0.307    8.82   1.18e-18
2 idade           -0.443      0.132   -3.35   8.12e- 4
3 classe_II       -1.52       0.329   -4.61   3.97e- 6
4 classe_III      -2.65       0.337   -7.87   3.54e-15
5 sexo_masculino  -2.40       0.243   -9.89   4.65e-23
6 sozinho_sim      0.0145     0.242    0.0598 9.52e- 1
```

```
final_glm <- extract_fit_engine(final)
class(final_glm)
```

```
[1] "glm" "lm"
```

10 Análise de resíduos do modelo final

Usamos os resíduos deviance do modelo final, ajustado no conjunto de treino.

```
dados_res <- tibble(
  ajustado = fitted(final_glm),
  residuo = residuals(final_glm, type = "deviance")
)

ggplot(dados_res, aes(ajustado, residuo)) +
  geom_point(alpha = 0.4) +
  geom_hline(yintercept = 0, linetype = "dashed") +
  labs(x = "Probabilidade ajustada", y = "Resíduo deviance")
```

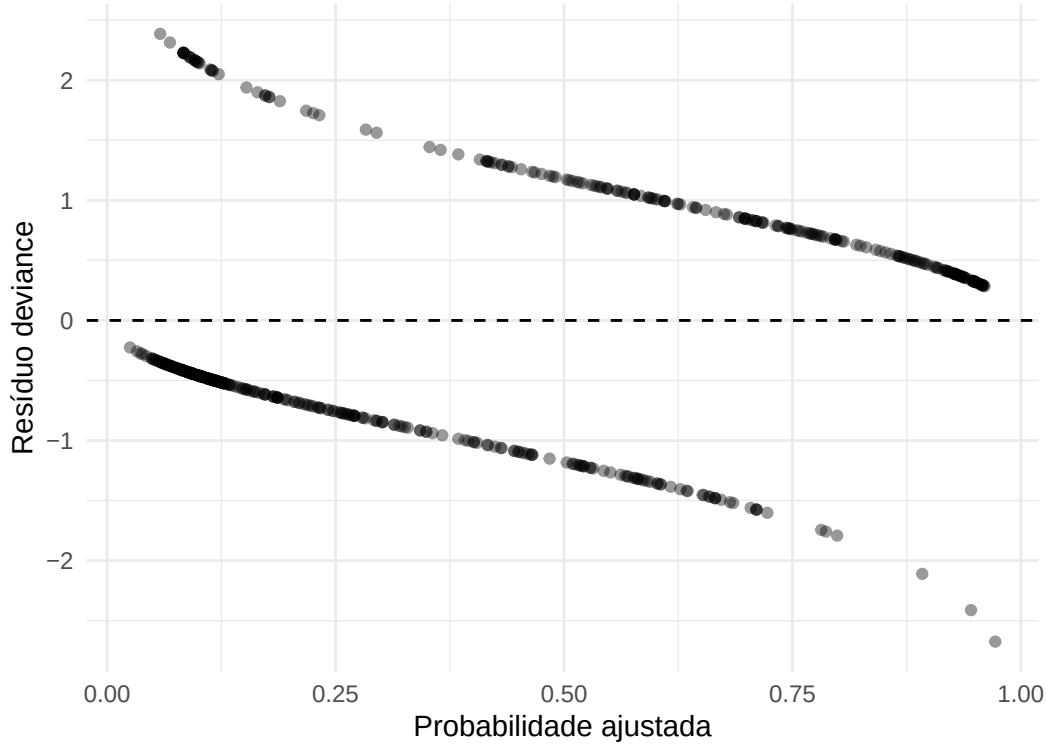


Figura 3: Resíduos deviance contra probabilidades ajustadas.

Como a resposta é binária (sobreviveu ou não), os resíduos formam duas faixas, uma para cada resultado. Essa forma é esperada para este tipo de modelo, por isso o gráfico ajuda pouco a detectar problemas.

11 Avaliação no conjunto de teste

Predições do modelo final nas observações que não foram usadas no ajuste.

```
preds_teste <- predict(final, new_data = teste, type = "prob") |>
  bind_cols(predict(final, new_data = teste, type = "class")) |>
  bind_cols(teste |> select(vivo))

head(preds_teste)
```

```
# A tibble: 6 x 4
  .pred_nao .pred_sim .pred_class vivo
      <dbl>     <dbl> <fct>       <fct>
1    0.892     0.108  nao         nao
2    0.0724    0.928  sim         sim
3    0.601     0.399  nao         nao
4    0.464     0.536  sim         sim
5    0.932     0.0678 nao         nao
6    0.494     0.506  sim         nao
```

```
# "sim" é o evento de interesse, por isso event_level = "second"
roc_auc(preds_teste, truth = vivo, .pred_sim, event_level = "second")
```

```
# A tibble: 1 x 3
  .metric .estimator .estimate
  <chr>   <chr>          <dbl>
```

```
1 roc_auc binary         0.866
```

```
# Escore de Brier calculado diretamente:
# média de (probabilidade prevista de "sim" - resultado observado)^2
mean((preds_teste$.pred_sim - as.numeric(preds_teste$vivo == "sim"))^2)
```

```
[1] 0.1398434
```

```
accuracy(preds_teste, truth = vivo, estimate = .pred_class)
```

```
# A tibble: 1 x 3
  .metric  .estimator .estimate
  <chr>    <chr>          <dbl>
1 accuracy binary         0.804
```

Matriz de confusão, usando o ponto de corte padrão de 0,5.

```
conf_mat(preds_teste, truth = vivo, estimate = .pred_class)
```

```
          Truth
Prediction nao sim
       nao  86  15
       sim  20  58
```

```
preds_teste |>
  roc_curve(truth = vivo, .pred_sim, event_level = "second") |>
  autoplot()
```

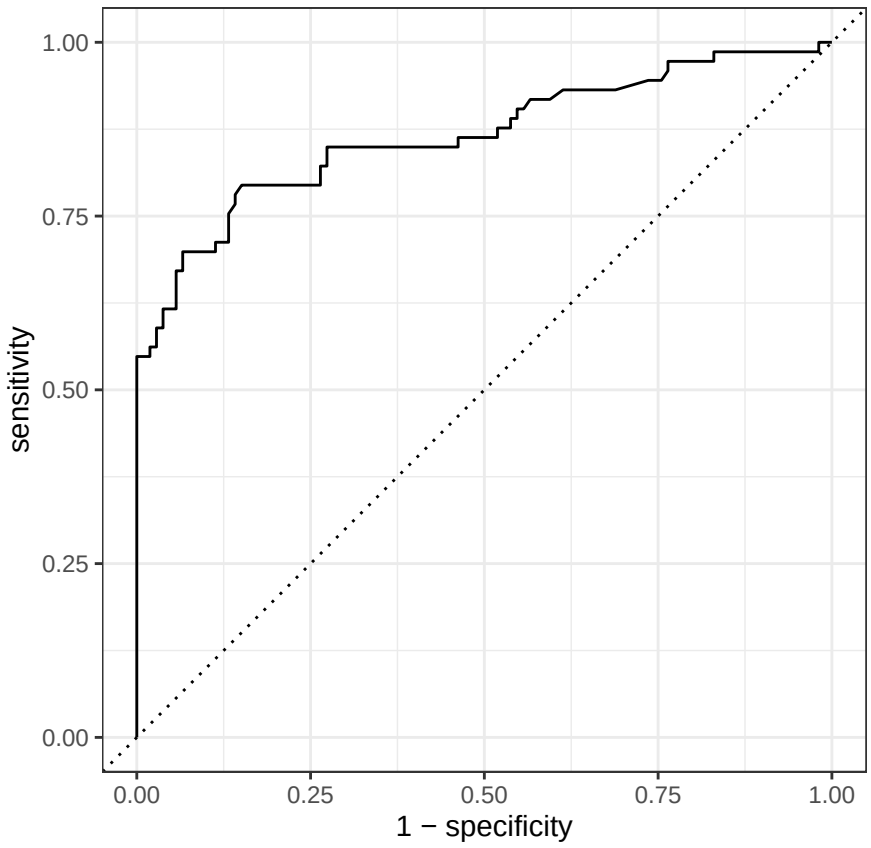


Figura 4: Curva ROC no conjunto de teste (pacote yardstick).

Conferência da AUC com o pacote pROC.

```r
roc_obj <- roc(
  response = teste$vivo,
  predictor = preds_teste$.pred_sim,
  levels = c("nao", "sim")
)

auc(roc_obj)
```

```
Area under the curve: 0.8658
```

12 Conclusões

Principais fatores. Sexo, classe e idade estão associados à sobrevivência, mesmo quando as outras variáveis são mantidas fixas.

- **Sexo:** a chance de sobreviver de um homem foi cerca de 0,08 vez a de uma mulher (razão de chances; intervalo de 95%: 0,05 a 0,12).
- **Classe:** em relação à classe I, a razão de chances foi 0,26 na classe II e 0,07 na classe III.
- **Idade:** cada ano a mais reduz a chance de sobreviver em cerca de 4% (razão de chances de 0,96 por ano; intervalo de 95%: 0,95 a 0,98).
- **Viajar sozinho:** não há evidência de efeito (p = 0,51 no teste da razão de verossimilhanças; razão de chances de 1,15, com intervalo de 0,76 a 1,73). Na tabela descritiva, quem viajava sozinho sobreviveu menos, mas esse efeito some quando se considera sexo, idade e classe.

Escolha da ligação. Os três modelos têm desempenho praticamente igual. Na validação cruzada, a AUC foi 0,843 (logit), 0,842 (probit) e 0,842 (cloglog). No ajuste com todos os dados, o cloglog teve o menor AIC (653 contra 659 do logit). Mantivemos o logit porque ele teve a maior AUC média, como no roteiro da disciplina. A diferença entre eles é muito pequena.

Desempenho no conjunto de teste. Com 179 passageiros que não entraram no ajuste:

- AUC de 0,866.
- Acurácia de 0,804, ou seja, 35 erros em 179 casos.
- Escore de Brier de 0,140, quanto menor, melhor.

Limitações.

- O banco tem 281 linhas repetidas. Não há identificador de passageiro, então não sabemos se são pessoas diferentes com as mesmas características. Mantivemos essas linhas, mas repetições podem tornar as métricas da validação cruzada um pouco otimistas.
- Os resultados mostram associação, não causa.
- Os dados se referem a um único naufrágio, em 1912.